

# Regresión Lineal Múltiple

Carmen Lancho - Natalia Madrueño

DSLAB

2026-02-18



El modelo de regresión lineal múltiple constituye la **extensión natural y más potente** del modelo simple.

## Diferencias clave:

### Regresión Simple:

- Una variable respuesta
- Un único predictor
- Relación bivariada

### Regresión Múltiple:

- Una variable respuesta
- **Múltiples predictores**
- Relación multivariada

## Capacidades únicas:

- **Modelar simultáneamente** el efecto de múltiples variables predictoras
- **Interpretación de coeficientes** en presencia de otros predictores
- **Diagnóstico específico** del modelo múltiple
- Manejo de la **multicolinealidad**

1. **Formular y estimar** modelos de regresión lineal múltiple, comprendiendo las diferencias clave respecto al caso simple
2. **Interpretar coeficientes** en el contexto multivariante, entendiendo el concepto de *ceteris paribus*
3. **Realizar inferencia estadística** construyendo intervalos de confianza y contrastes de hipótesis
4. **Evaluar la calidad del ajuste** usando medidas como  $R^2$ ,  $R^2$  ajustado y descomposición ANOVA
5. **Diagnosticar el modelo múltiple** aplicando técnicas específicas como gráficos CPR
6. **Identificar y tratar la multicolinealidad** usando el VIF como herramienta de diagnóstico
7. **Realizar predicciones** distinguiendo entre intervalos de confianza e intervalos de predicción

Para  $n$  observaciones y  $p$  variables predictoras, el **modelo poblacional** postula:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_p X_{ip} + \varepsilon_i, \quad i = 1, \dots, n$$

## Componentes:

- $Y_i$ :  $i$ -ésima variable respuesta aleatoria
- $X_{ij}$ :  $i$ -ésima variable predictora aleatoria del  $j$ -ésimo predictor
- $\varepsilon_i$ : término de error aleatorio
- $\beta_0, \beta_1, \dots, \beta_p$ : coeficientes poblacionales verdaderos pero desconocidos

## Características clave:

- Relación **lineal en los parámetros**
- Los errores son **no observables**
- Los parámetros son **constantes poblacionales**

En la práctica, trabajamos con **datos observados** y estimamos el modelo:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \cdots + \hat{\beta}_p x_{ip}, \quad i = 1, \dots, n$$

## Componentes:

- $\hat{y}_i$ :  $i$ -ésima predicción
- $x_{ij}$ :  $i$ -ésima observación del  $j$ -ésimo predictor
- $\hat{\beta}_j$ : coeficientes estimados

## Interpretación clave de $\hat{\beta}_j$ :

El cambio estimado en la media de  $Y$  ante un cambio de una unidad en  $X_j$ , **manteniendo constantes todas las demás variables predictoras**.

Este principio se conoce como ***ceteris paribus*** (“lo demás constante”)

## Modelo poblacional:

$$\mathbf{Y} = \tilde{X}\beta + \varepsilon$$

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}, \quad \tilde{X} = \begin{bmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix}$$

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}, \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

**Nota:**  $\tilde{X}$  contiene variables aleatorias (mayúsculas  $X_{ij}$ )

## Modelo muestral:

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$$

$$\hat{\mathbf{y}} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}, \quad \hat{\boldsymbol{\beta}} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{bmatrix}$$

## Observaciones:

- $\mathbf{X}$  contiene datos observados (minúsculas  $x_{ij}$ )
- $\mathbf{X}$  y  $\tilde{\mathbf{X}}$  son matrices de dimensión  $n \times (p + 1)$
- La primera columna de unos corresponde al intercepto  $\beta_0$

## Condiciones de Gauss-Markov:

1. **Linealidad en los parámetros:** El modelo  $E[\mathbf{Y}|\tilde{\mathbf{X}}] = \tilde{\mathbf{X}}\beta$  está bien especificado
2. **Exogeneidad:** Los errores tienen media cero:  $E[\varepsilon|\tilde{\mathbf{X}}] = \mathbf{0}$
3. **Homocedasticidad e independencia:**  $\text{Var}(\varepsilon|\tilde{\mathbf{X}}) = \sigma^2\mathbf{I}_n$
4. **Ausencia de multicolinealidad perfecta:**  $\mathbf{X}$  tiene rango completo ( $p + 1$ )
5. **Normalidad (para inferencia):**  $\varepsilon \sim N(\mathbf{0}, \sigma^2\mathbf{I}_n)$

**Implicación:** Estos supuestos garantizan que los estimadores MCO sean **insesgados, consistentes y eficientes**



**Principio:** Minimizar la discrepancia entre valores observados y predichos

**Función objetivo:**

$$S(\beta) = \sum_{i=1}^n e_i^2 = \mathbf{e}^T \mathbf{e} = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$$

**¿Por qué cuadrados?**

- Los residuos positivos y negativos no se cancelan
- Se penalizan más fuertemente los errores grandes
- Facilita el tratamiento matemático

**Resultado:** MCO minimiza la **Suma de los Cuadrados de los Residuos** (SSR)

**Expandiendo la función objetivo:**

$$S(\beta) = \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T (\mathbf{X}^T \mathbf{X}) \beta$$

**Derivando respecto a  $\beta$ :**

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}^T \mathbf{y} + 2(\mathbf{X}^T \mathbf{X}) \beta$$

**Igualando a cero:**

$$-2\mathbf{X}^T \mathbf{y} + 2(\mathbf{X}^T \mathbf{X}) \hat{\beta} = \mathbf{0}$$

**Ecuaciones Normales:**

$$(\mathbf{X}^T \mathbf{X}) \hat{\beta} = \mathbf{X}^T \mathbf{y}$$

**Solución única:**

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

**Condición necesaria:** La matriz  $(\mathbf{X}^T \mathbf{X})$  debe ser invertible

**¿Cuándo es invertible?**

- Cuando  $\mathbf{X}$  tiene rango completo  $(p + 1)$
- Cuando las columnas de  $\mathbf{X}$  son linealmente independientes
- Cuando no hay multicolinealidad perfecta

**Propiedades de  $(\mathbf{X}^T \mathbf{X})$ :**

- Dimensión:  $(p + 1) \times (p + 1)$
- Simétrica
- Definida positiva (si es invertible)

## Bajo los supuestos de Gauss-Markov:

1. **Insesgados:**  $E[\hat{\beta}] = \beta$
2. **Eficientes:** Varianza mínima entre todos los estimadores lineales insesgados
3. **Consistentes:**  $\hat{\beta} \xrightarrow{p} \beta$  cuando  $n \rightarrow \infty$

## Matriz de varianza-covarianza:

$$\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$$

## Bajo normalidad adicional:

$$\hat{\beta} \sim N(\beta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1})$$

**Estimador insesgado de  $\sigma^2$ :**

$$\hat{\sigma}^2 = \frac{\text{SSE}}{n - p - 1} = \frac{\sum_{i=1}^n e_i^2}{n - p - 1} = \frac{\mathbf{e}^T \mathbf{e}}{n - p - 1}$$

**Grados de libertad:**  $n - p - 1$

- $n$ : número de observaciones
- $p + 1$ : número de parámetros estimados

**Distribución:**

$$\frac{(n - p - 1)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-p-1}^2$$

**Error estándar de los coeficientes:**

$$\hat{\sigma}_{\beta_j} = \hat{\sigma} \sqrt{(\mathbf{X}^T \mathbf{X})_{jj}^{-1}}$$

**Datos:** Precios de viviendas basados en características

**Variables predictoras:**

- superficie: Metros cuadrados
- habitaciones: Número de habitaciones
- antigüedad: Años de antigüedad
- distancia\_centro: Distancia al centro (km)
- garaje: Presencia de garaje (Sí/No)

## Coeficiente de regresión parcial:

$$\beta_j = \frac{\partial E[Y|\tilde{X}]}{\partial X_j}$$

**Interpretación:**  $\beta_j$  representa el cambio esperado en  $Y$  por una unidad de cambio en  $X_j$ , **manteniendo todas las demás variables constantes**

## Diferencia crucial:

### Regresión Simple:

- Efecto **total** (directo + indirecto)
- Puede estar **confundido**
- $\hat{\beta}_j$  captura toda la asociación

### Regresión Múltiple:

- Efecto **puro** o **parcial**
- **Controla** por otras variables
- Interpretación más **causal**

**Concepto clave:** El coeficiente proviene de una regresión entre residuos

|                  | Estimate   | Std. Error |
|------------------|------------|------------|
| (Intercept)      | 53750.9705 | 6666.70624 |
| superficie       | 1171.7780  | 47.28087   |
| habitaciones     | 15072.3104 | 1303.41715 |
| antigüedad       | -744.5896  | 75.42075   |
| distancia_centro | -2028.2715 | 164.87756  |
| garajeSí         | 25829.4317 | 2349.44285 |

## Interpretación *ceteris paribus*:

- **Superficie** (+1,172 €/m<sup>2</sup>): Cada m<sup>2</sup> adicional incrementa el precio
- **Habitaciones** (+15,072 €): Cada habitación adicional aumenta el precio
- **Antigüedad** (-745 €/año): Cada año de antigüedad reduce el precio
- **Distancia centro** (-2,028 €/km): Cada km más lejos del centro reduce el precio
- **Garaje** (+25,829 €): Tener garaje incrementa el precio



## Descomposición ANOVA:

$$SST = SSR + SSE$$

### Donde:

- **SST** (Sum of Squares Total):  $\sum_{i=1}^n (y_i - \bar{y})^2$
- **SSR** (Sum of Squares Regression):  $\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$
- **SSE** (Sum of Squares Error):  $\sum_{i=1}^n (y_i - \hat{y}_i)^2$

### Interpretación:

- **SST**: Variabilidad total en los datos
- **SSR**: Variabilidad explicada por el modelo
- **SSE**: Variabilidad no explicada (residual)

**R-cuadrado:**

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

**Interpretación:**

- Proporción de la variabilidad en  $Y$  explicada por el modelo
- Rango:  $0 \leq R^2 \leq 1$
- $R^2 = 0$ : El modelo no explica nada
- $R^2 = 1$ : El modelo explica toda la variabilidad

**Problema:**  $R^2$  siempre aumenta al añadir variables (incluso irrelevantes)

**En regresión múltiple:**  $R^2$  es el cuadrado de la correlación entre  $y$  y  $\hat{y}$

## R-cuadrado ajustado:

$$R_{\text{adj}}^2 = 1 - \frac{\text{SSE}/(n - p - 1)}{\text{SST}/(n - 1)} = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

## Ventajas:

- **Penaliza** la inclusión de variables irrelevantes
- **Puede decrecer** si una variable no aporta información suficiente
- Mejor para **comparar modelos** con diferente número de predictores

## Criterio de decisión:

- Si  $R_{\text{adj}}^2$  aumenta al añadir una variable  $\rightarrow$  la variable es útil
- Si  $R_{\text{adj}}^2$  disminuye  $\rightarrow$  la variable no aporta información suficiente

## Hipótesis sobre un coeficiente:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0$$

## Estadístico de contraste:

$$t = \frac{\hat{\beta}_j - 0}{\hat{\sigma}_{\beta_j}} = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{(\mathbf{X}^T \mathbf{X})_{jj}^{-1}}} \sim t_{n-p-1}$$

## Interpretación:

- **Rechazar**  $H_0$ : La variable  $X_j$  es estadísticamente significativa
- **No rechazar**  $H_0$ : No hay evidencia de efecto lineal de  $X_j$  sobre  $Y$

**Valor p:** Probabilidad de observar un estadístico  $t$  tan extremo o más, bajo  $H_0$

**Intervalo de confianza al  $(1 - \alpha)\%$ :**

$$\hat{\beta}_j \pm t_{\alpha/2, n-p-1} \cdot \hat{\sigma}_{\beta_j}$$

**Interpretación:**

- Con  $(1 - \alpha)\%$  de confianza, el verdadero valor de  $\beta_j$  está en este intervalo
- Si el intervalo **no contiene cero**  $\rightarrow \beta_j$  es significativo
- Si el intervalo **contiene cero**  $\rightarrow \beta_j$  no es significativo

**Relación con el test de hipótesis:**

- Intervalo de confianza del 95%  $\equiv$  Test de hipótesis con  $\alpha = 0.05$
- Si 0 está en el IC del 95%  $\rightarrow$  No se rechaza  $H_0$  al 5%

## Hipótesis global:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0 \quad \text{vs} \quad H_1 : \text{Al menos un } \beta_j \neq 0$$

## Estadístico F:

$$F = \frac{SSR/p}{SSE/(n-p-1)} = \frac{R^2/p}{(1-R^2)/(n-p-1)} \sim F_{p,n-p-1}$$

## Interpretación:

- **Rechazar  $H_0$ :** El modelo es globalmente significativo
- **No rechazar  $H_0$ :** El modelo no explica variabilidad significativa

**Relación con  $R^2$ :** El test F evalúa si  $R^2$  es significativamente diferente de cero

```
Call:
lm(formula = precio ~ superficie + habitaciones + antigüedad +
    distancia_centro + garaje, data = viviendas)
```

Residuals:

|  | Min    | 1Q     | Median | 3Q   | Max   |
|--|--------|--------|--------|------|-------|
|  | -38847 | -11074 | 867    | 9898 | 38486 |

Coefficients:

|                  | Estimate | Std. Error | t value | Pr(> t ) |     |
|------------------|----------|------------|---------|----------|-----|
| (Intercept)      | 53750.97 | 6666.71    | 8.063   | 7.53e-14 | *** |
| superficie       | 1171.78  | 47.28      | 24.783  | < 2e-16  | *** |
| habitaciones     | 15072.31 | 1303.42    | 11.564  | < 2e-16  | *** |
| antigüedad       | -744.59  | 75.42      | -9.872  | < 2e-16  | *** |
| distancia_centro | -2028.27 | 164.88     | -12.302 | < 2e-16  | *** |
| garajeSí         | 25829.43 | 2349.44    | 10.994  | < 2e-16  | *** |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15950 on 194 degrees of freedom

Multiple R-squared: 0.9094, Adjusted R-squared: 0.9071

F-statistic: 289.4 on 5 and 194 DF, p-value: < 2.2e-16

**Predicción puntual:** Para un nuevo vector  $\mathbf{x}_0$ :

$$\hat{y}_0 = \mathbf{x}_0^T \hat{\beta}$$

**Dos tipos de intervalos:**

**Intervalo de Confianza:**

- Para la **respuesta media**  $E[Y|\mathbf{x}_0]$
- Incertidumbre en la estimación
- Más estrecho

**Intervalo de Predicción:**

- Para una **observación individual**  $Y_0$
- Incertidumbre + variabilidad natural
- Más amplio

**Fórmulas:** Ambos dependen de  $\hat{\sigma}^2$  y de la matriz  $(\mathbf{X}^T \mathbf{X})^{-1}$



**Intervalo de confianza para la respuesta media:**

$$\hat{y}_0 \pm t_{\alpha/2, n-p-1} \cdot \hat{\sigma} \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

**Intervalo de predicción para una observación individual:**

$$\hat{y}_0 \pm t_{\alpha/2, n-p-1} \cdot \hat{\sigma} \sqrt{1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

**Diferencia clave:** El “+1” en el intervalo de predicción refleja la variabilidad adicional de una observación individual

**Amplitud:** Intervalo de predicción > Intervalo de confianza

Una vez ajustado el modelo, es **fundamental realizar un diagnóstico exhaustivo** para verificar que los supuestos se cumplen.

**Base del diagnóstico: Análisis de los residuos** - nuestra ventana a los errores teóricos no observables

## Supuestos a verificar:

### 1. Normalidad

- Gráfico Q-Q de residuos
- Test de Shapiro-Wilk

### 2. Independencia

- Residuos vs tiempo
- Test de Durbin-Watson

### 3. Homocedasticidad

- Gráfico Scale-Location
- Test de Breusch-Pagan

### 4. Linealidad

- Residuos vs valores ajustados
- **Gráficos CPR** (específicos de múltiple)

**Problema:** El gráfico residuos vs ajustados puede ocultar una relación no lineal con **una variable específica**

**Solución:** Gráficos CPR para cada predictor  $X_j$ :






$$\text{Residuo Parcial} = e_i + \hat{\beta}_j x_{ij} \quad \text{vs.} \quad x_{ij}$$

**Interpretación:**

- **Línea sólida:** Relación lineal esperada
- **Línea punteada:** Suavizado no paramétrico
- **Coincidencia:** Linealidad adecuada
- **Divergencia:** Posible no-linealidad  $\rightarrow$  necesita transformación

**Ventaja:** Permite detectar no-linealidades específicas de cada variable

## Gráficos de Componente + Residuo



## ¿Qué observamos en las 5 variables?

### Superficie y Habitaciones:

- Líneas sólida y punteada coinciden
- **Conclusión:** Relación lineal adecuada

### Garaje:

- Separación clara entre grupos (No/Sí)
- **Conclusión:** Efecto categórico apropiado

**Clave:** Si las líneas divergen significativamente → considerar transformaciones

### Antigüedad y Distancia:

- Líneas coinciden bien
- **Conclusión:** Linealidad confirmada

### Interpretación general:

- Relaciones lineales apropiadas
- No se necesitan transformaciones

¿Qué es? Correlación alta entre variables predictoras

**Consecuencias:**

1. **Varianza inflada:** Errores estándar muy grandes
2. **Inestabilidad:** Pequeños cambios en datos  $\rightarrow$  grandes cambios en coeficientes
3. **Contradicciones:** Modelo globalmente significativo pero ningún predictor individual significativo

**Nota importante:** La multicolinealidad **NO viola** los supuestos de Gauss-Markov, pero **arruina la interpretación práctica**

**Detección:**

- **Matriz de correlaciones:** Correlaciones  $> 0.8$  son señal de alerta
- **VIF:** Herramienta definitiva de diagnóstico

## Proceso de cálculo del VIF para $X_j$ :

1. Regresar  $X_j$  sobre **todas las demás variables predictoras**
2. Obtener el  $R_j^2$  de este modelo auxiliar
3. Calcular:

$$VIF_j = \frac{1}{1 - R_j^2}$$

**Interpretación:** Factor por el cual se infla la varianza de  $\hat{\beta}_j$  debido a multicolinealidad

## Reglas prácticas:

- **VIF = 1:** Ausencia de colinealidad (ideal)
- **VIF > 5:** Valores preocupantes que requieren atención
- **VIF > 10:** Multicolinealidad seria que debe ser tratada

Caso 1: Sin problemas de multicolinealidad

|            |              |            |
|------------|--------------|------------|
| superficie | habitaciones | antigüedad |
| 1.40       | 1.40         | 1.01       |

|                  |        |
|------------------|--------|
| distancia_centro | garaje |
| 1.01             | 1.01   |

Caso 2: Con multicolinealidad problemática

|                |                  |                  |
|----------------|------------------|------------------|
| superficie_sim | habitaciones_sim | metros_cuadrados |
| 86.4           | 8.5              | 81.2             |

Correlación superficie-metros\_cuadrados: 0.994



**La estrategia depende del objetivo del análisis:**

## 1. No hacer nada

- Si el objetivo es **predicción**
- Si variables colineales no son de interés

## 2. Eliminar variables

- Quitar la menos relevante teóricamente
- Mantener la más correlacionada con Y

## 3. Combinar variables

- Crear índices compuestos
- Análisis de Componentes Principales

## 4. Métodos alternativos

- **Ridge regression:** Reduce varianza añadiendo sesgo
- **Lasso/Elastic Net:** Regresión penalizada

## 5. Aumentar muestra

- Más datos pueden reducir correlaciones
- No siempre factible

## Conceptos básicos (como en regresión simple):

- **Outlier:** Residuo grande
- **Leverage:** Valor atípico en predictores
- **Influencia:** Impacto en el modelo

## Herramientas específicas de regresión múltiple:

**DFBETAS:** Influencia sobre coeficientes individuales

$$\text{DFBETA}_{j,i} = \frac{\hat{\beta}_j - \hat{\beta}_{j(-i)}}{\text{se}(\hat{\beta}_{j(-i)})}$$

**Criterio:**  $|\text{DFBETA}_{j,i}| > \frac{2}{\sqrt{n}}$  es problemático

**Ventaja:** Permite identificar qué observaciones afectan a qué coeficientes específicos

**Objetivo:** Visualizar la relación entre  $Y$  y  $X_j$  **después de eliminar el efecto lineal de todos los demás predictores**

**Construcción:**

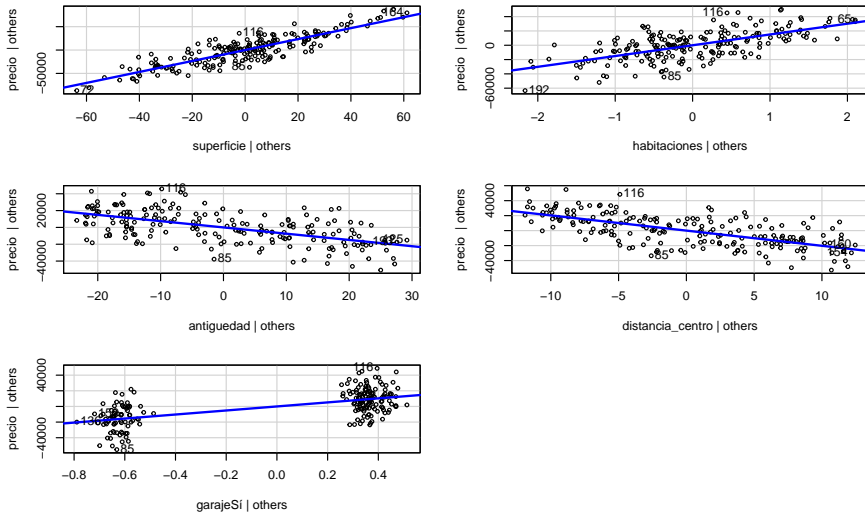
1. Residuos de  $Y$  regresado sobre todos los predictores excepto  $X_j$ :  $e_{Y|X_{-j}}$
2. Residuos de  $X_j$  regresado sobre todos los demás predictores:  $e_{X_j|X_{-j}}$
3. Graficar:  $e_{Y|X_{-j}}$  vs  $e_{X_j|X_{-j}}$

**Propiedad mágica:** La pendiente de la línea ajustada es **exactamente**  $\hat{\beta}_j$

**Utilidades:**

- Visualizar magnitud y significancia del efecto “ajustado”
- Detectar no-linealidades en relaciones parciales
- Identificar observaciones influyentes para coeficientes específicos

## Gráficos de regresión parcial



## ¿Qué vemos en cada gráfico?

- **Eje X:** Residuos de  $X_j$  vs. todos los demás predictores
- **Eje Y:** Residuos de  $Y$  vs. todos los demás predictores (excepto  $X_j$ )
- **Pendiente:** Es exactamente el coeficiente  $\hat{\beta}_j$  del modelo múltiple

## Interpretación por variable:

- **Superficie:** Relación lineal clara, pendiente positiva
- **Habitaciones:** Relación positiva, algunos puntos influyentes
- **Antigüedad:** Relación negativa evidente
- **Distancia:** Relación negativa clara
- **Garaje:** Separación clara entre grupos (No/Sí)

## La regresión múltiple permite:

1. **Efectos parciales:** Aislar el impacto de cada variable predictora
2. **Control de confusores:** Reducir sesgos por variables omitidas
3. **Mejores predicciones:** Incorporar múltiples fuentes de información
4. **Relaciones complejas:** Modelar fenómenos multifactoriales

## Aspectos críticos:

- **Interpretación condicional:** Los coeficientes son efectos parciales (*ceteris paribus*)
- **Notación matricial:** Fundamental para la comprensión y computación
- **Supuestos:** Base para las propiedades de los estimadores
- **$R^2$  ajustado:** Mejor que  $R^2$  para comparar modelos
- **Inferencia:** Tests individuales (t) y global (F)

**Próximo paso:** Diagnóstico del modelo y tratamiento de problemas específicos